Laporan Tugas 05: Transfer Learning untuk Klasifikasi Citra dengan Data Terbatas

Nama: Rizky Mirzaviandy Priambodo
NIM: 2802549041

Bagian A: Analisis Konseptual

A1. Efek regularisasi Batch Normalization (Slide 6 sampai 8)

Saat training, BatchNorm menormalkan aktivasi pakai mean dan variance dari satu mini batch, bukan dari seluruh data. Angka ini cuma perkiraan, jadi ada noise. Hasil normalisasi satu sampel ikut bergantung pada sampel lain di batch yang sama, dan berubah tiap iterasi. Efeknya mirip Dropout, karena jaringan jadi tidak bisa terlalu bergantung pada nilai aktivasi yang persis (Ioffe & Szegedy, 2015). Saat inference, BatchNorm pakai running statistics, jadi noisenya hilang.

Anggapan "Dropout tidak perlu lagi" tidak selalu benar. Pertama, batch kecil (misalnya 2 sampai 8) bikin statistiknya terlalu berisik dan training jadi tidak stabil; GroupNorm lebih cocok di sini (Wu & He, 2018). Kedua, di batch yang sangat besar noisenya hampir hilang, jadi efek regularisasinya lemah. Ketiga, head fully connected yang besar dengan data sedikit tetap bisa overfit. Keempat, Dropout yang dipasang sebelum BatchNorm menggeser variance antara train dan inference (variance shift), jadi performa turun (Li et al., 2019).

A2. Degradasi jaringan dalam dan formulasi residual (Slide 10 sampai 12)

Secara teori, jaringan yang lebih dalam bisa meniru jaringan dangkal kalau lapisan tambahannya belajar identity mapping. Kenyataannya, optimizer berbasis SGD susah menemukan fungsi identitas lewat tumpukan konvolusi dan fungsi nonlinear. Hasilnya, training error plain CNN 56 lapis lebih tinggi daripada yang 20 lapis (He et al., 2016). Training accuracy ikut turun, jadi penyebabnya adalah masalah optimisasi.

Residual block mengubah targetnya jadi $y = F(x) + x$. Kalau identitas memang yang terbaik, model cukup mendorong $F(x)$ ke nol, dan itu jauh lebih mudah. Saat backpropagation, $\partial L/\partial x = \partial L/\partial y \cdot (\partial F/\partial x + I)$. Suku identitas I memberi gradien jalan langsung ke lapisan awal. Di Sesi 02, vanishing gradient terjadi karena gradien adalah hasil kali banyak Jacobian dengan norma di bawah satu, jadi nilainya mengecil secara eksponensial. Dengan skip connection, gradien jadi jumlah dari banyak jalur. Jalur identitas tidak lewat perkalian itu, jadi sinyalnya tidak hilang.

A3. Feature Extraction vs. Fine Tuning (Slide 14 sampai 16)

Dimensi	Feature Extraction	Fine Tuning
Trainable parameters	Hanya head (di eksperimen ini 5.130)	Head + blok yang dibuka (layer4 + fc: 8.398.858)
Kebutuhan data	Sedikit; puluhan citra per kelas sudah cukup	Lebih banyak, supaya blok yang dibuka tidak overfit
Komputasi dan memori per epoch	Rendah; tidak ada backward pass lewat backbone dan aktivasi tidak perlu disimpan untuk gradien	Lebih tinggi; ada backward pass dan state optimizer untuk jutaan parameter
Risiko fitur bawaan rusak	Nol; bobot backbone tidak berubah	Ada, terutama kalau learning rate besar dan datanya sedikit

Aturan praktisnya (Yosinski et al., 2014): pakai feature extraction kalau datanya sangat sedikit dan domainnya mirip ImageNet, atau kalau komputasinya terbatas. Pakai fine tuning kalau datanya cukup, domainnya beda (misalnya citra medis atau satelit), atau kalau kelasnya butuh fitur tingkat tinggi yang spesifik. Fine tuning sebagian di blok terakhir dengan learning rate kecil adalah jalan tengah yang aman.

A4. Kaidah data augmentation (Slide 20, 21, 23)

Augmentasi adalah regularizer yang memperluas variasi data train dengan transformasi yang tidak mengubah label. Validation dan test set harus mengukur performa di data asli, yaitu data yang nanti dihadapi di produksi. Kalau augmentasi acak dipakai saat evaluasi, metriknya jadi berisik (beda tiap run), tidak bisa dibandingkan antar model, dan tidak menggambarkan input yang sebenarnya. Early stopping yang memantau validation loss juga jadi tidak bisa dipercaya. Karena itu evaluasi cuma pakai transformasi tetap (Resize, CenterCrop, Normalize).

Contoh transformasi yang tidak cocok untuk ras hewan peliharaan adalah color jitter yang kuat, terutama perubahan hue atau konversi ke grayscale. Warna bulu adalah ciri pembeda ras. Russian Blue hampir pasti abu kebiruan, Birman punya "sarung tangan" putih, dan Bengal punya pola rosette cokelat oranye. Kalau hue diubah, British Shorthair krem bisa terlihat seperti ras lain, jadi labelnya tidak lagi tetap setelah transformasi.

A5. Mitigasi catastrophic forgetting (Slide 28 sampai 29)

Catastrophic forgetting terjadi karena bobot pretrained sudah ada di titik minimum yang bagus untuk ImageNet. Head baru masih acak, jadi di epoch awal gradiennya besar, berisik, dan ikut mengalir ke backbone. Kalau learning rate backbone besar, bobotnya bergeser jauh dari titik tadi sebelum head stabil. Fitur umum rusak dan diganti fitur yang overfit ke data kecil (Kirkpatrick et al., 2017; McCloskey & Cohen, 1989).

Strategi 1, differential learning rate: backbone pakai learning rate 10× lebih kecil dari head (di sini 1e-4 vs 1e-3). Backbone sudah berisi fitur yang bagus dan cukup diubah sedikit, sementara head belajar dari nol.

Strategi 2, gradual unfreezing (Howard & Ruder, 2018): latih head dulu dengan backbone dibekukan, lalu buka blok satu per satu dari atas. Saat backbone dibuka, head sudah memberi gradien yang berguna, jadi update di backbone lebih kecil dan terarah. B3 memakai versi sederhana keduanya, yaitu hanya membuka layer4 dengan learning rate kecil.

Bagian B: Setup Eksperimen

Data yang dipakai adalah 10 kelas dari Oxford-IIIT Pet (Parkhi et al., 2012): Bengal, Birman, British Shorthair, Ragdoll, Russian Blue, American Pit Bull Terrier, Basset Hound, Beagle, Pug, dan Staffordshire Bull Terrier. Datanya dibagi stratified 70/15/15, jadi ada 1.392 citra train, 298 val, dan 299 test.

Semua run ResNet-18 pakai bobot `IMAGENET1K_V1`, input 224×224 dengan normalisasi ImageNet, batch 32, AdamW (weight decay 1e-2), dan CrossEntropyLoss. Training maksimal 20 epoch, dengan early stopping pada val loss (patience 4) dan seed 42. Semuanya dijalankan di GPU NVIDIA RTX 4050 Laptop.

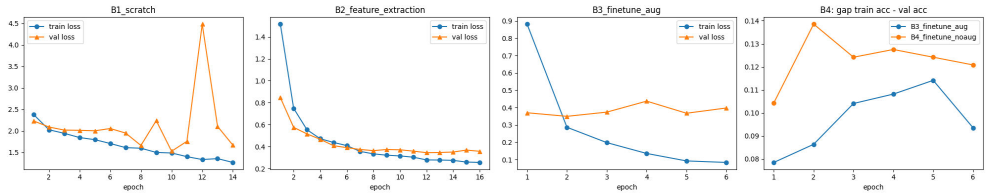
Augmentasi hanya dipakai di data train, yaitu RandomResizedCrop(224, 0.8 sampai 1.0), HorizontalFlip, Rotation 15°, dan ColorJitter(0.2, 0.2). Val dan test cuma diberi Resize 256 dan CenterCrop 224. B4 memakai kondisi B3 tanpa augmentasi. B5 memakai EfficientNet-B0 (Tan & Le, 2019) dengan `features[6:]` dibuka (lr 1e-4) dan classifier dengan lr 1e-3.

Bagian C: Laporan dan Analisis

C1. Tabel konsolidasi

Run	Trainable params	Learning rate	Epoch terbaik (berhenti)	Waktu (s)	Train acc	Val acc	Test acc	Test Macro F1
B1 scratch	11.181.642	all 1e-3	10 (14)	109,3	0,478	0,426	0,445	0,410
B2 feature extraction	5.130	fc 1e-3	12 (16)	78,7	0,931	0,852	0,849	0,851
B3 fine tuning + aug	8.398.858	layer4 1e-4, fc 1e-3	2 (6)	31,7	0,945	0,859	0,863	0,862
B4 fine tuning tanpa aug	8.398.858	layer4 1e-4, fc 1e-3	2 (6)	22,1	0,994	0,856	0,873	0,873
B5 EfficientNet-B0 + aug	3.168.550 / 4.020.358	features[6:] 1e-4, cls 1e-3	7 (11)	72,8	0,994	0,899	0,936	0,937

Train acc diukur tanpa augmentasi, pada bobot terbaik.



Kurva loss B1, B2, B3 dan gap B4

C2. Pembahasan

1. Kenapa B1 jauh di bawah B2 dan B3?

F1 B1 cuma 0,410, sedangkan B2 0,851 dan B3 0,862. B1 harus mempelajari 11,2 juta parameter dari 1.392 citra saja. Val loss B1 naik turun (paling rendah 1,53 di epoch 10, lalu melonjak ke 4,49 di epoch 12) padahal train loss terus turun, jadi model belum membentuk fitur umum. Residual connection (Slide 10 sampai 12) memang bikin jaringan mudah dioptimasi, tapi tidak bisa menggantikan data. Model pretrained sudah membawa fitur dari ImageNet. Val loss B2 di epoch pertama (0,85) sudah jauh lebih bagus dari val loss terbaik B1 (1,53).

2. Feature extraction vs. fine tuning (Slide 16, 28)

B2 paling stabil, karena train loss dan val loss turun bareng. B3 cuma sedikit lebih bagus (F1 +0,011, val acc +0,007), tapi konvergen jauh lebih cepat (epoch 2 vs 12) dan waktu trainingnya 2,5× lebih singkat. B3 kurang stabil. Val loss B3 paling rendah di epoch 2 lalu naik, sementara train loss terus turun. Jadi B3 butuh early stopping dan learning rate kecil di layer4. Dengan data sekecil ini, tambahan akurasi dari fine tuning kecil.

3. Peran augmentasi (B4, Slide 20)

Augmentasi jelas menahan overfitting. Tanpa augmentasi, train acc 0,994 dan gap train−val 0,139. Dengan augmentasi, train acc 0,945 dan gap 0,086. Tapi test F1 tidak naik (0,862 dengan augmentasi vs 0,873 tanpa augmentasi; bedanya sekitar 3 citra). Dugaan saya, B3 sudah berhenti di epoch 2, jadi augmentasi belum sempat membantu, dan fitur pretrained sudah cukup tahan terhadap flip dan perubahan warna kecil. Karena cuma satu seed, beda di test ini tidak signifikan.

4. Arsitektur pembanding (B5, Slide 24)

EfficientNet-B0 dapat F1 tertinggi (0,937) dengan total parameter 2,8× lebih sedikit. Tapi trainingnya 2,3× lebih lama dari B3 (73 s vs 32 s) karena jalan lebih banyak epoch.

C3. Failure analysis

Model ResNet-18 terbaik (B3, dipilih dari val acc) salah di 41 dari 299 citra test. Ini delapan kesalahan dengan confidence tertinggi:



Sampel misklasifikasi

#	Aktual	Prediksi (conf.)	Hipotesis
1	Basset Hound	Beagle (0,99)	Fotonya dekat ke wajah, jadi kaki pendek dan badan panjang Basset tidak kelihatan. Warna tricolornya sama dengan Beagle.
2	British Shorthair	Ragdoll (0,98)	Corak abu dan putih jarang ada di data train British Shorthair; pola putih di wajah dan dada mirip Ragdoll.
3	Russian Blue	British Shorthair (0,97)	Dua ras ini mirip, dan wajah bulat serta mata kuning di foto ini lebih khas British Shorthair.
4	Russian Blue	British Shorthair (0,94)	Sudut dari bawah dan cahaya hangat mengubah warna bulu dan bentuk kepala.
5	Staffordshire Bull Terrier	American Pit Bull Terrier (0,93)	Dua ras ini hampir sama, dan ukuran tubuh tidak kelihatan tanpa pembanding; sudut rendah dan harness menutupi bentuk dada.
6	Ragdoll	Birman (0,91)	Keduanya colorpoint, berbulu panjang, dan bermata biru; kaki putihnya mirip "sarung tangan" Birman.
7	Basset Hound	Beagle (0,88)	Pose melompat menyembunyikan kaki pendek dan badan panjang; ada motion blur.
8	Russian Blue	British Shorthair (0,86)	Foto dekat dengan mulut terbuka; mata kuning dan pipi lebar lebih mirip British Shorthair.

Semua kesalahan terjadi di antara ras yang mirip. Tidak ada kucing yang tertukar dengan anjing. Confidence yang tinggi di prediksi yang salah berarti model terlalu yakin.

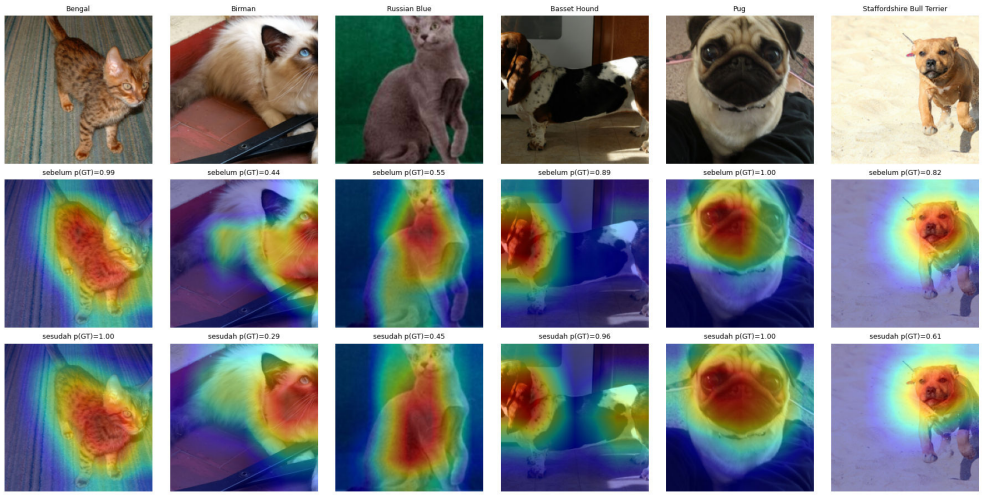
C4. Rekomendasi dan batasan

Rekomendasi saya untuk data terbatas (sekitar 140 citra per kelas, domain mirip ImageNet):

1. Kalau akurasi paling penting, pakai EfficientNet-B0 dengan fine tuning sebagian (B5). F1 run ini paling tinggi dan modelnya paling kecil.
2. Untuk ResNet-18, feature extraction (B2) sudah jadi baseline yang kuat dan stabil. Fine tuning sebagian (B3) cuma menambah sedikit, tapi konvergen lebih cepat. Kalau dipakai, wajib pakai differential learning rate dan early stopping.
3. Tetap pakai augmentasi untuk menahan overfitting, walaupun manfaatnya di test belum kelihatan di eksperimen satu seed ini.
4. Jangan latih dari nol di skala data ini.

Hasil ini berasal dari satu seed saja, dan test setnya kecil (1 citra = 0,33 poin akurasi). Kelasnya cuma 10 dan domainnya dekat dengan ImageNet. Hyperparameter tidak di tuning, dan waktu training diukur di satu laptop GPU.

C5. Grad-CAM layer4



Grad-CAM sebelum dan sesudah fine tuning

Peta Grad-CAM (Selvaraju et al., 2017) dihitung di layer4. B2 pakai layer4 ImageNet yang dibekukan (sebelum), B3 pakai layer4 yang sudah di fine tuning (sesudah). Setelah fine tuning, peta aktivasinya bergeser. Di Basset Hound, fokus tetap di kepala dan telinga panjang, dan p(GT) naik dari 0,89 ke 0,96. Di Birman, fokus pindah ke wajah yang bertopeng. Di kelas yang mudah (Bengal, Pug), petanya hampir sama, jadi fitur ImageNet tidak rusak. Tapi p(GT) turun di Birman (0,44 → 0,29), Russian Blue (0,55 → 0,45), dan Staffordshire (0,82 → 0,61). Ketiganya punya ras pasangan yang mirip (Ragdoll, British Shorthair, Pit Bull), jadi model yang sudah di fine tuning membagi probabilitasnya ke ras pasangan itu. Rata rata cosine similarity fitur layer4 sebelum dan sesudah adalah 0,88, jadi representasinya berubah tapi tetap dekat dengan titik pretrained (Slide 29).

Referensi

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 770–778). IEEE. https://doi.org/10.1109/CVPR.2016.90

Howard, J., & Ruder, S. (2018). Universal language model fine-tuning for text classification. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 328–339). Association for Computational Linguistics. https://doi.org/10.18653/v1/P18-1031

Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *Proceedings of the 32nd International Conference on Machine Learning* (Vol. 37, pp. 448–456). PMLR.

Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A. A., Milan, K., Quan, J., Ramalho, T., Grabska-Barwinska, A., Hassabis, D., Clopath, C., Kumaran, D., & Hadsell, R. (2017). Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences, 114*(13), 3521–3526. https://doi.org/10.1073/pnas.1611835114

Li, X., Chen, S., Hu, X., & Yang, J. (2019). Understanding the disharmony between dropout and batch normalization by variance shift. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 2677–2685). IEEE. https://doi.org/10.1109/CVPR.2019.00279

McCloskey, M., & Cohen, N. J. (1989). Catastrophic interference in connectionist networks: The sequential learning problem. In G. H. Bower (Ed.), *Psychology of learning and motivation* (Vol. 24, pp. 109–165). Academic Press. https://doi.org/10.1016/S0079-7421(08)60536-8

Parkhi, O. M., Vedaldi, A., Zisserman, A., & Jawahar, C. V. (2012). Cats and dogs. In *2012 IEEE Conference on Computer Vision and Pattern Recognition* (pp. 3498–3505). IEEE. https://doi.org/10.1109/CVPR.2012.6248092

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. In *Proceedings of the IEEE International Conference on Computer Vision* (pp. 618–626). IEEE. https://doi.org/10.1109/ICCV.2017.74

Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. In *Proceedings of the 36th International Conference on Machine Learning* (Vol. 97, pp. 6105–6114). PMLR.

Wu, Y., & He, K. (2018). Group normalization. In *Computer Vision – ECCV 2018* (Lecture Notes in Computer Science, Vol. 11217, pp. 3–19). Springer. https://doi.org/10.1007/978-3-030-01261-8_1

Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? In *Advances in Neural Information Processing Systems 27* (pp. 3320–3328). Curran Associates.

Lampiran: Pernyataan Penggunaan AI (AI Disclosure Statement)

1. Nama model/alat AI: Claude dari Anthropic.
2. Ruang lingkup bantuan: menjelaskan konsep materi dan membantu membuat draf laporan PDF.
3. Cara verifikasi: saya menjalankan notebook dari awal sampai akhir tanpa eror, memeriksa jumlah trainable parameters dan pembagian data, mencocokkan setiap angka dan tabel di laporan dengan output notebook, serta membaca ulang seluruh isi laporan.